
Introduction To Data Analysis
데이터분석입문
Lecture 30. pandas로 연령별 인구구조 유사지역 분석
인공지능소프트웨어학과 강환수 교수

학습개요

- 연령별 인구 데이터를 pandas로 읽어와 전처리 및 기본 연산
- 연령별 인구구조 분석을 위한 관심 지역 선정과 유사한 연령별 인구구조 지역을 찾기 위한 계산
- 관심지역과 유사한 연령별 인구구조 지역 5개 데이터 시각화

학습목표

- 연령별 인구 데이터 pandas로 읽어와 기본 전처리와 기본 연산을 수행할 수 있다.
- 연령별 인구구조 분석을 위한 관심 지역을 선정해 DataFrame에 저장할 수 있다
- 관심지역과 유사한 연령별 인구구조 지역을 찾기 위한 계산을 수행할 수 있다.
- 관심지역과 유사한 연령별 인구구조 지역 5개의 데이터 시각화를 할 수 있다.

LESSON 01

연령별 인구구조 DataFrame 저장과 전처리

알고리즘(Algorithm) 설계하기

Step 1) 데이터를 읽어온다.

- ⓐ 행정구역의 총 인구수가 0인 행을 제거한다.
- ⓑ 전체 데이터를 총 인구수로 나누어 비율로 변환한다.
- ⓒ 총 인구수와 연령 구간 인구수를 삭제한다.

Step 2) 궁금한 지역의 이름을 입력 받는다.

Step 3) 궁금한 지역의 인구 구조를 저장한다.

Step 4) 궁금한 지역의 인구 구조와 가장 비슷한 인구 구조를 가진 지역을 찾는다.

- ⓐ 전국의 모든 지역 중 한 곳(B)를 선택한다.
- ⓒ 100세 이상 인구수에 해당하는 값까지 선정된 지역과의 차이의 제곱을 모두 더한다.
- ⓓ 전국의 모든 지역에 대해 반복하며 그 차이가 가장 작은 지역을 찾는다.

Step 5) 가장 비슷한 곳의 인구 구조와 궁금한 지역의 인구 구조를 시각화한다.

Step 1) 데이터를 읽어 오기 (1/2)

첫 열이 index(행 제목)가 되도록: index_col=0

```python
import pandas as pd

df = pd.read_csv('age.csv', encoding='cp949', index_col=0)
df.head()
```

✓ 0.5s Python

	2023년09월_계_총인구수	2023년09월_계_연령구간인구수	2023년09월_계_0세	2023년09월_계_1세	2023년09월_계_2세	2023년09월_계_3세	2023년09월_계_4세	2023년09월_계_5세	2023년09월_계_6세	2023년09월_계_7세	...	2023년09월_계_91세	2023년09월_계_92세	2023년09월_계_93세	2023년09월_계_94세	20년
행정구역																
서울특별시 (1100000000)	9,407,540	9,407,540	38,101	41,599	43,518	44,893	48,097	51,107	56,215	64,176	...	8,984	6,319	5,441	4,430	3,1
서울특별시 종로구 (1111000000)	139,945	139,945	397	470	463	524	516	578	670	778	...	172	146	110	93	
서울특별시 종로구 청운효자동 (1111051500)	11,391	11,391	35	45	46	47	50	47	76	86	...	14	14	7	8	

데이터를 확인해 보면
숫자 사이에 쉼표(,)가 있습니다.
자료형을 확인해 보겠습니다.

Step 1) 데이터를 읽어 오기 (2/2)

```
import pandas as pd

df = pd.read_csv('age.csv', encoding='cp949', index_col=0)
df.dtypes
```

```
2021년11월_계_총인구수          object
2021년11월_계_연령구간인구수     object
2021년11월_계_0세              object
2021년11월_계_1세              object
2021년11월_계_2세              object
                              ...
2021년11월_계_96세             object
2021년11월_계_97세             object
2021년11월_계_98세             object
2021년11월_계_99세             object
2021년11월_계_100세 이상       object
Length: 103, dtype: object
```

정수형 자료형이 아니라 객체(object) 입니다.
정수형 자료형으로 변환하기 전에
숫자 사이에 있는 쉼표(,)부터 제거하겠습니다.

콤마 제거

```
import pandas as pd

df = pd.read_csv('age.csv', encoding='cp949', index_col=0)

df = df.replace(',', '', regex=True)
df.head()
```

replace( ) 함수를 이용하면 전체 데이터 프레임에서 쉼표(,)를 한 번에 ”으로 바꿀 수가 있습니다.

행정구역	2021년11월_계_총인구수	2021년11월_계_연령구간인구수	2021년11월_계_0세	2021년11월_계_1세	2021년11월_계_2세	2021년11월_계_3세	2021년11월_계_4세	2021년11월_계_5세	2021년11월_계_6세	2021년11월_계_7세	...	2021년11월_계_91세	2021년11월_계_92세	2021년11월_계_93세	2021년11월_계_94세	2021년11월_계_95세	2021년11월_계_96세	2021년11월_계_97세	2021년11월_계_98세	2021년11월_계_99세	20년
서울특별시 (1100000000)	9520880	9520880	43492	45054	49318	51995	56210	63757	67763	66950	...	8147	6779	5328	4048	2587	1862	1368	1274	816	20
서울특별시 종로구 (1111000000)	145073	145073	486	475	557	576	664	773	848	859	...	183	139								
서울특별시 종로구 청운효자동 (1111051500)	12006	12006	43	48	58	54	80	74	96	93	...	10	10								
서울특별시 종로구 사직동 (1111053000)	9367	9367	38	27	40	46	55	67	74	71	...	15	19	6	7	8	9	2	3	1	
서울특별시 종로구 삼청동 (1111054000)	2467	2467	7	5	3	10	14	6	17	8	...	7	2	4	3	1	0	2	0	2	

5 rows × 103 columns

regex 옵션은 regular expression의 약자로,
정규 표현식으로 문자열이 완전히 일치하지 않더라도
문자열의 일부분만 치환하고 싶을 경우 True로 설정해줍니다.

이제 정수형 자료형으로
변환해 보겠습니다.

정수로 변환

```
import pandas as pd

df = pd.read_csv('age.csv', encoding='cp949', index_col=0)

df = df.replace(',', '', regex=True)

df = df.apply(pd.to_numeric)
df.dtypes
```

```
2021년11월_계_총인구수          int64
2021년11월_계_연령구간인구수      int64
2021년11월_계_0세              int64
2021년11월_계_1세              int64
2021년11월_계_2세              int64
                              ...
2021년11월_계_96세             int64
2021년11월_계_97세             int64
2021년11월_계_98세             int64
2021년11월_계_99세             int64
2021년11월_계_100세 이상        int64
Length: 103, dtype: object
```

객체(object)에서 정수형 자료형 “int64”로 변경되었습니다.

행정구역의 총 인구수가 0인 행 제거

```
# 전체 코드
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

df = pd.read_csv('age.csv', encoding='cp949', index_col=0)

# 콤마로 제거하고 정수로 변환
df = df.replace(',', '', regex=True)
df = df.apply(pd.to_numeric)

# 총 인구수가 0인 행을 삭제
df = df[df[df.columns[0]] != 0]
```

행정구역 이름이 '~~~출장소' 등으로 되어 있으면서
총 인구수가 0이 아닌 지역만을 추출해서 다시 df에 저장한다.

인구비율 계산

```python
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

df = pd.read_csv('age.csv', encoding='cp949', index_col=0)

# 콤마로 제거하고 정수로 변환
df = df.replace(',', '', regex=True)
df = df.apply(pd.to_numeric)

# 총 인구수가 0인 행을 삭제
df = df[df[df.columns[0]] != 0]

# df = df.div(df['2023년09월_계_총인구수'], axis='index')
df = df.div(df[df.columns[0]], axis='index')
df.head(3)
```

0.5s Python

행정구역	2023년09월_계_총인구수	2023년09월_계_연령구간인구수	2023년09월_계_0세	2023년09월_계_1세	2023년09월_계_2세	2023년09월_계_3세	2023년09월_계_4세	2023년09월_계_5세	2023년09월_계_6세	2023년09월_계_7세	...	2023년09월_계_91세	2023년09월_계_92세
서울특별시 (1100000000)	1.0	1.0	0.004050	0.004422	0.004626	0.004772	0.005113	0.005433	0.005976	0.006822	...	0.000955	0.000672
서울특별시 종로구 (1111000000)	1.0	1.0	0.002837	0.003358	0.003308	0.003744	0.003687	0.004130	0.004788	0.005559	...	0.001229	0.001043
서울특별시 종로구 청운효자동 (1111051500)	1.0	1.0	0.003073	0.003950	0.004038	0.004126	0.004389	0.004126	0.006672	0.007550	...	0.001229	0.001229

3 rows × 103 columns

ⓐ 전체 데이터를 총 인구수로 나누어 비율로 변환한다.

필요 없는 열 제거

```python
import pandas as pd

df = pd.read_csv('age.csv', encoding='cp949', index_col = 0)
df = df.replace(',', '', regex=True)

df = df.apply(pd.to_numeric)

# 총 인구수가 0인 행을 삭제
df = df[df[df.columns[0]] != 0]

df = df.div(df['2023년09월_계_총인구수'], axis='index')
del df['2023년09월_계_총인구수'], df['2023년09월_계_연령구간인구수']

df.head(3)
```

✓ 0.5s Python

ⓑ 총 인구수와 연령 구간 인구수를 삭제한다.

	2023년 09월_계 _0세	2023년 09월_계 _1세	2023년 09월_계 _2세	2023년 09월_계 _3세	2023년 09월_계 _4세	2023년 09월_계 _5세	2023년 09월_계 _6세	2023년 09월_계 _7세	2023년 09월_계 _8세	2023년 09월_계 _9세	...	2023년 09월_계 _91세	20 09
행정구역													
서울특별시 (1100000000)	0.004050	0.004422	0.004626	0.004772	0.005113	0.005433	0.005976	0.006822	0.007074	0.007078	...	0.000955	0.00
서울특별시 종로구 (1111000000)	0.002837	0.003358	0.003308	0.003744	0.003687	0.004130	0.004788	0.005559	0.005681	0.005981	...	0.001229	0.00
서울특별시 종로구 청운효자동 (1111051500)	0.003073	0.003950	0.004038	0.004126	0.004389	0.004126	0.006672	0.007550	0.007550	0.007462	...	0.001229	0.00

3 rows × 101 columns

LESSON 02

pandas로 연령별 인구구조 유사지역 시각화

관심 지역의 인구구조 저장 (1/2)

```python
import pandas as pd

df = pd.read_csv('age.csv', encoding='cp949', index_col = 0)
df = df.replace(',', '', regex=True)

df = df.apply(pd.to_numeric)

# 총 인구수가 0인 행을 삭제
df = df[df[df.columns[0]] != 0]

df = df.div(df['2023년09월_계_총인구수'], axis='index')
del df['2023년09월_계_총인구수'], df['2023년09월_계_연령구간인구수']

name = input('원하는 지역의 이름을 입력해주세요 : ') #2. 지역 이름 입력
a = df.index.str.contains(name) #3. 해당 행을 찾아서 해당 지역의 인구 구조를 저장
df2 = df[a]
df2
```

✓ 11.9s Python

df.index.str.contains( ) 함수는
데이터 프레임의 인덱스 문자열로부터,
원하는 문자열이 포함된 행을 찾아냅니다.

행정구역	2023년 09월_계 _0세	2023년 09월_계 _1세	2023년 09월_계 _2세	2023년 09월_계 _3세	2023년 09월_계 _4세	2023년 09월_계 _5세	2023년 09월_계 _6세	2023년 09월_계 _7세	2023년 09월_계 _8세	2023년 09월_계 _9세	...	2023년 09월_계 _91세	20 09
서울특별시 구로구 신도림동 (1153051000)	0.006206	0.007016	0.007128	0.007296	0.008582	0.007631	0.008442	0.010259	0.011489	0.010846	...	0.000559	0.00

관심 지역의 인구구조 저장 (2/2)

```
import pandas as pd
import matplotlib.pyplot as plt

df = pd.read_csv('age.csv', encoding='cp949', index_col = 0)
df = df.replace(',', '', regex=True)

df = df.apply(pd.to_numeric)

# 총 인구수가 0인 행을 삭제
df = df[df[df.columns[0]] != 0]

df = df.div(df['2023년09월_계_총인구수'], axis='index')
del df['2023년09월_계_총인구수'], df['2023년09월_계_연령구간인구수']

name = input('원하는 지역의 이름을 입력해주세요 : ') #2. 지역 이름 입력

a = df.index.str.contains(name) #3. 해당 행을 찾아서 해당 지역의 인구 구조를 저장
df2 = df[a]
```

```
# plt.rc('font', family='Malgun Gothic')
plt.rcParams['font.family'] = 'Malgun Gothic'
df2.T.plot()
plt.show()
```

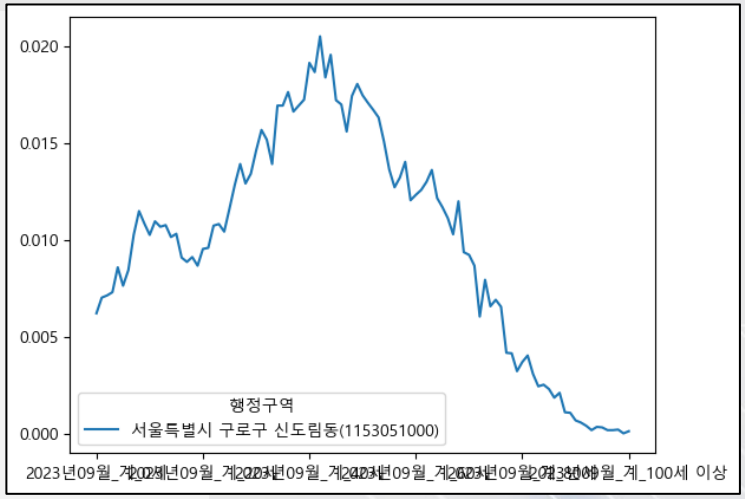

pandas의 Series나 DataFrame은
plot( ) 메서드를 내장하고 있습니다.

관심 지역과 유사 인구구조 지역 시각화 (1/4)

```
# A의 인구 비율에서 B의 인구 비율을 뺀다.
x = df.sub(df2.iloc[0], axis='columns')   # axis=1 이라고 적어도 됩니다.
x.head(3)
```

행정구역	2021년11월_계_0세	2021년11월_계_1세	2021년11월_계_2세	2021년11월_계_3세	2021년11월_계_4세	2021년11월_계_5세	2021년11월_계_6세	2021년11월_계_7세	2021년11월_계_8세	2021년11월_계_9세	...	2021년11월_계_91세	2021년11월_계_92세	2021년11월_계_93세
서울특별시 (1100000000)	-0.003051	-0.002775	-0.003690	-0.002992	-0.003022	-0.003786	-0.004728	-0.004174	-0.003284	-0.003071	...	0.000466	0.000267	0.000198
서울특별시 종로구 (1111000000)	-0.004269	-0.004233	-0.005031	-0.004482	-0.004349	-0.005154	-0.006000	-0.005284	-0.004664	-0.004193	...	0.000872	0.000513	0.000424
서울특별시 종로구 청운효자동 (1111051500)	-0.004037	-0.003510	-0.004039	-0.003955	-0.002262	-0.004319	-0.003849	-0.003460	-0.003486	-0.000877	...	0.000444	0.000388	0.000471

3 rows × 101 columns

관심 지역과 유사 인구구조 지역 시각화 (2/4)

```
import numpy as np

y = np.power(x, 2)
z = y.sum(axis='columns')
z
```

✓ 0.0s

```
행정구역
서울특별시  (1100000000)                0.000551
서울특별시 종로구 (1111000000)            0.001098
서울특별시 종로구 청운효자동(1111051500)      0.000512
서울특별시 종로구 사직동(1111053000)         0.000730
서울특별시 종로구 삼청동(1111054000)         0.001673
                                      ...
제주특별자치도 서귀포시 서홍동(5013058000)     0.000644
제주특별자치도 서귀포시 대륜동(5013059000)     0.000337
제주특별자치도 서귀포시 대천동(5013060000)     0.000328
제주특별자치도 서귀포시 중문동(5013061000)     0.000305
제주특별자치도 서귀포시 예래동(5013062000)     0.002119
Length: 3862, dtype: float64
```

관심 지역과 유사 인구구조 지역 시각화 (3/4)

```
i = z.sort_values().index[:6]
i
```

✓ 0.0s

```
Index(['서울특별시 구로구 신도림동(1153051000)', '경기도 하남시 (4145000000)',
       '경기도 남양주시 별내동(4136057000)', '서울특별시 영등포구 문래동(1156060500)',
       '충청남도 아산시 (4420000000)', '서울특별시 영등포구 신길제7동(1156069000)'],
      dtype='object', name='행정구역')
```

sort_values( ) 함수를 활용하여 오름차순으로 정렬하고,
index[:6]를 활용하여 차이가 0인 관심지역과 가장 작은 지역 5곳을 찾습니다.

관심 지역과 유사 인구구조 지역 시각화 (4/4)

```python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

plt.rc('font', family ='Malgun Gothic')
plt.rcParams['axes.unicode_minus'] = False
df.loc[i].T.plot(figsize=(10, 6))
plt.xlabel('나이')
plt.ylabel('인구 비율')
plt.grid(True)
plt.show()
```

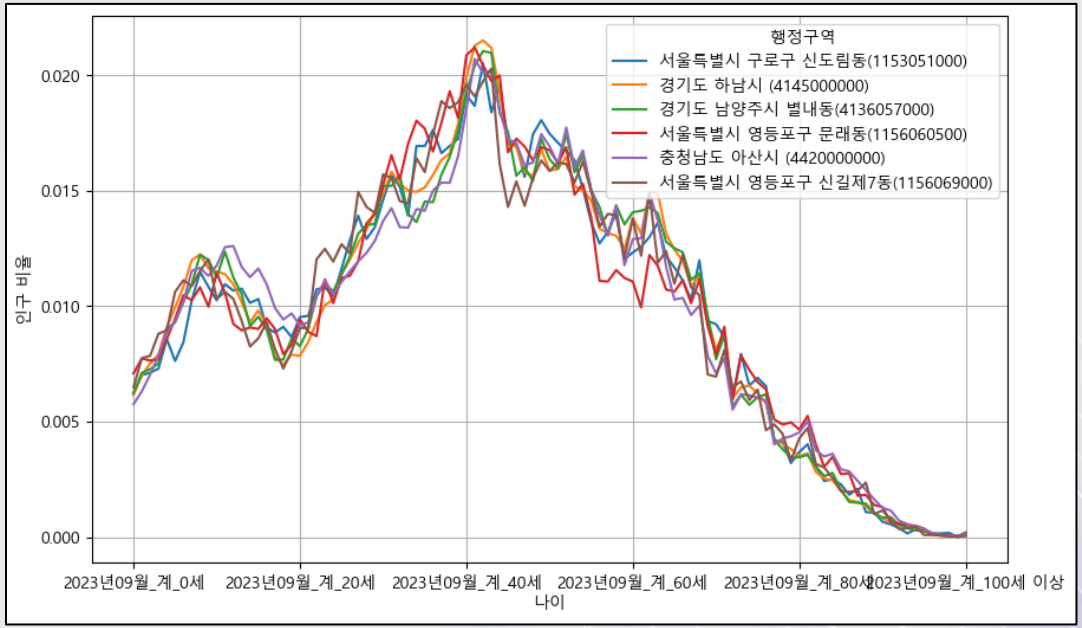

loc은 location의 약자로 인덱스를 기준으로
행 데이터를 읽기 위해서 사용됩니다.

[참고] iloc은 행 번호를 기준으로
행 데이터를 읽기 위해서 사용됩니다.

전체 코드

```
# 전체 코드
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

df = pd.read_csv('age.csv', encoding='cp949', index_col=0)

# 콤마로 제거하고 정수로 변환
df = df.replace(',', '', regex=True)
df = df.apply(pd.to_numeric)

# 총 인구수가 0인 행을 삭제
df = df[df[df.columns[0]] != 0]

# df = df.div(df['2023년09월_계_총인구수'], axis='index')
df = df.div(df[df.columns[0]], axis='index')
del df['2023년09월_계_총인구수'], df['2023년09월_계_연령구간인구수']

name = input('원하는 지역의 이름을 입력해주세요 : ') # 원하는 지역 이름 입력
df2 = df[df.index.str.contains(name)] #3. 해당 행을 찾아서 해당 지역의 인

# 특정 지역의 인구를 빼고
x = df.sub(df2.iloc[0], axis='columns')
y = np.power(x, 2) # 차의 제곱을 연산
z = y.sum(axis='columns') # 결과는 시리즈로 인덱스가 행정 구역
i = z.sort_values().index[:6] # 차의 제곱이 가장 작은 6개 선택

plt.rcParams['font.family'] = 'Malgun Gothic'
plt.rcParams['axes.unicode_minus'] = False

df.columns = range(101)
df.loc[i].T.plot(figsize=(10, 6))
plt.xlabel('나이')
plt.ylabel('인구 비율')
plt.grid(True)
plt.show()
```

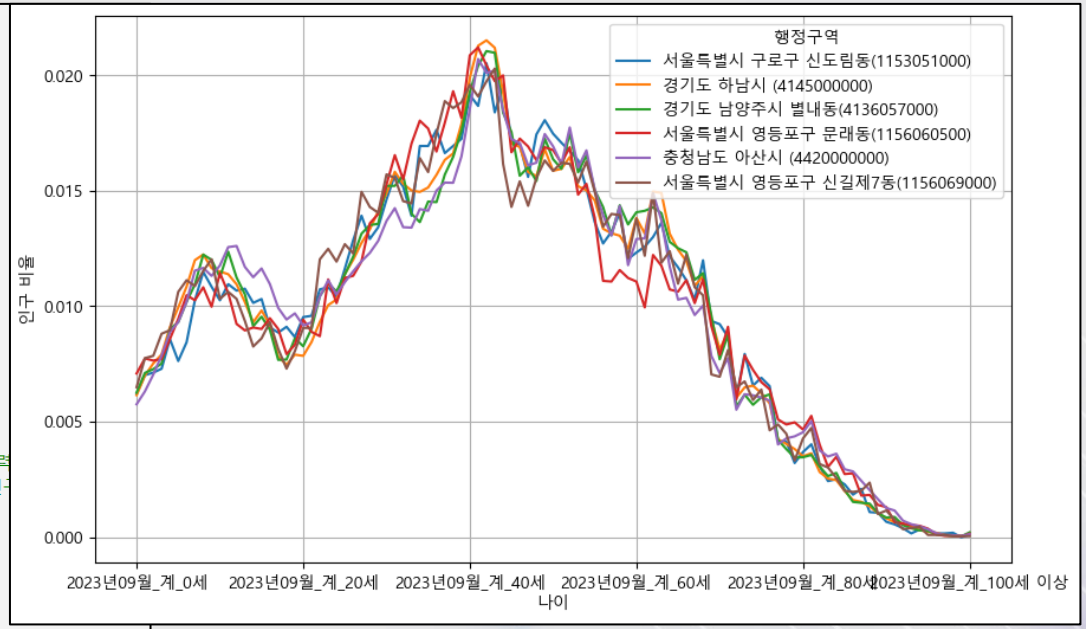

스타일 설정, 다른 지역 유사 검색

```
# 전체 코드
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

df = pd.read_csv('age.csv', encoding='cp949', index_col=0)

# 콤마로 제거하고 정수로 변환
df = df.replace(',', '', regex=True)
df = df.apply(pd.to_numeric)

# 총 인구수가 0인 행을 삭제
df = df[df[df.columns[0]] != 0]

# df = df.div(df['2023년09월_계_총인구수'], axis='index')
df = df.div(df[df.columns[0]], axis='index')
del df['2023년09월_계_총인구수'], df['2023년09월_계_연령구간인구수']

name = input('원하는 지역의 이름을 입력해주세요 : ') # 원하는 지역 이름 입력
df2 = df[df.index.str.contains(name)] #3. 해당 행을 찾아서 해당 지역의 인구 구조를 저장

# 특정 지역의 인구를 빼고
x = df.sub(df2.iloc[0], axis='columns')
y = np.power(x, 2) # 차의 제곱을 연산
z = y.sum(axis='columns') # 결과는 시리즈로 인덱스가 행정 구역
i = z.sort_values().index[:6] # 차의 제곱이 가장 작은 6개 선택

plt.rcParams['font.family'] = 'Malgun Gothic'
plt.rcParams['axes.unicode_minus'] = False

plt.style.use('ggplot')
df.columns = [f'{i}세' for i in range(101)]
df.loc[i].T.plot(figsize=(10, 6))
plt.xlabel('나이')
plt.ylabel('인구 비율')
plt.grid(True)

plt.xticks(range(0, 101, 10))
plt.show()
```

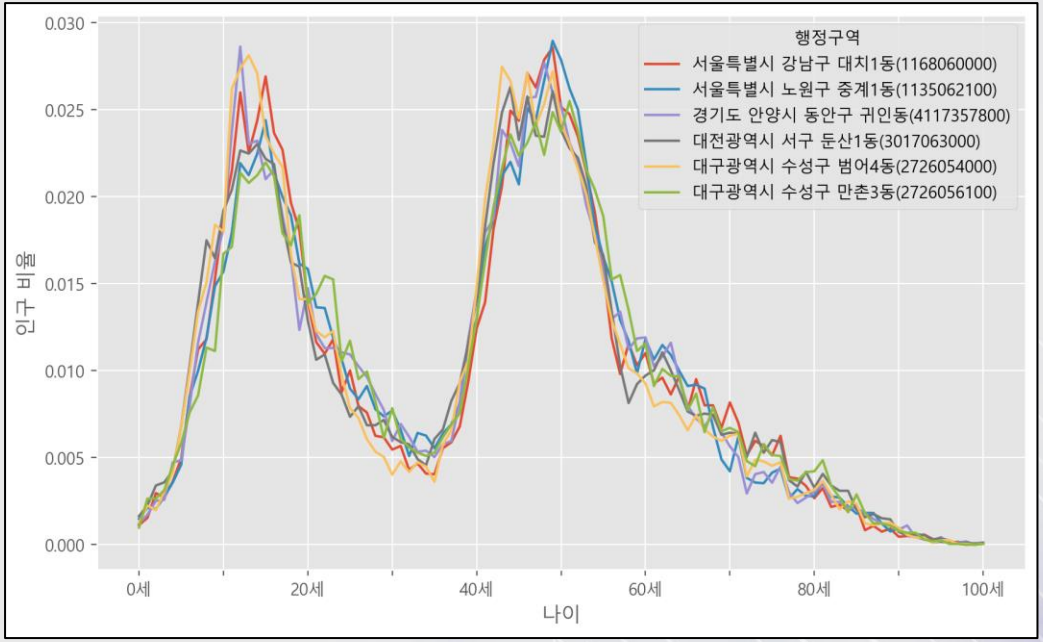

SUMMARY

학습정리

연령별 인구 데이터를 pandas로 읽어와 전처리 및 기본 연산

```
df = pd.read_csv('age.csv', encoding='cp949', index_col=0)
df = df.replace(',', '', regex=True)
df = df.apply(pd.to_numeric)
df = df[df[df.columns[0]] != 0]
df = df.div(df[df.columns[0]], axis='index')
```

연령별 인구구조 분석을 위한 관심 지역 선정

```
name = input('원하는 지역의 이름을 입력해주세요 : ') #2. 지역 이름 입력
a = df.index.str.contains(name) #3. 해당 행을 찾아서 해당 지역의 인구 구조를 저장
df2 = df[a]
```

관심 지역과 유사한 연령별 인구구조 지역을 찾기 위한 계산

```
x = df.sub(df2.iloc[0], axis='columns')
y = np.power(x, 2)
z = y.sum(axis='columns’)
```

관심지역과 유사한 연령별 인구구조 지역 5개 데이터 시각화

```
i = z.sort_values().index[:6] # 차의 제곱이 가장 작은 6개 선택
df.loc[i].T.plot(figsize=(10, 6))
```